



Data Science

Program Studi Informatika

Sesi 1 – Pengenalan Data Science

Syahid Abdullah, S.Si, M.Kom



Outline



Identitas & Capaian



Definisi Data Science



CRISP-DM



Ekosistem Tools



Hands-on



Referensi



Apa itu Data Science?

Definisi multidisiplin · Tiga pilar · Perkembangan industri · Peran karir



Definisi Data Science

"Data Science adalah bidang multidisiplin yang menggunakan metode ilmiah, proses algoritmik, dan sistem komputasi untuk mengekstrak pengetahuan dari data terstruktur maupun tidak terstruktur."

— Dhar (2013); Donoho (2017)



Statistika & Matematika

- Probabilitas & inferensi
- Regresi & korelasi
- Pengujian hipotesis
- Aljabar linear



Ilmu Komputer

- Pemrograman Python/R
- Machine learning
- Rekayasa data
- Manajemen basis data



Domain Knowledge

- Konteks bisnis
- Kesehatan & medis
- Ilmu sosial
- Teknik terapan



Fenomena Big Data dan Perkembangan Indonesia

Volume

Data yang dihasilkan tumbuh eksponensial. Setiap hari 2,5 quintilion byte data diciptakan.

Velocity

Kecepatan generasi dan pemrosesan data meningkat drastis; real-time streaming menjadi standar.

Variety

Data hadir dalam beragam format: teks, gambar, video, sensor, log, media sosial, dan lainnya.

Veracity

Kualitas dan kebenaran data menjadi tantangan utama; data kotor menghasilkan keputusan buruk.

Konteks Industri Indonesia

Gojek: Prediksi permintaan, fraud detection, rekomendasi driver

Tokopedia: Sistem rekomendasi produk, deteksi penjual palsu

Bank BRI: Penilaian kredit mikro UMKM berbasis model prediktif

BPJS Kes.: Deteksi fraud klaim & perencanaan layanan kesehatan nasional

Traveloka: Dynamic pricing tiket & hotel berdasarkan prediksi permintaan



Ekosistem Profesi Data Science



Data Analyst

SQL · Statistika · Visualisasi

- Analisis & visualisasi data
- Dashboard & laporan bisnis
- Menjawab pertanyaan bisnis konkret
- Entry-level, banyak dibutuhkan

Tableau, Power BI, Excel, SQL



Data Scientist

Python · ML · Statistika lanjut

- Membangun model ML & AI
- Riset & eksperimen data
- Menjawab pertanyaan kompleks
- Membutuhkan keahlian statistik kuat

Python, Scikit-learn, TensorFlow



ML Engineer

Software Eng · MLOps · Cloud

- Deploy model ke produksi
- Pipeline & infrastruktur ML
- Skalabilitas sistem AI
- Skill teknik paling tinggi

Docker, Kubernetes, MLflow, AWS



Data Engineer

Data Pipelines · Cloud · ETL

- Bangun infrastruktur data
- Pipeline ETL & ELT
- Data warehouse & data lake
- Fondasi untuk tim data science

Spark, Airflow, dbt, BigQuery




Siklus Proyek Data: CRISP-DM

6 Fase CRISP-DM · Sifat Iteratif · Metodologi Industri · Studi Kasus



Kerangka CRISP-DM



↺ Sifat iteratif: dapat kembali ke fase sebelumnya kapan saja



1 Business Understanding

Mendefinisikan tujuan bisnis yang ingin dicapai dan menerjemahkannya menjadi tujuan analitis yang konkret.

Aktivitas Utama:

- Tentukan tujuan bisnis yang terukur
- Nilai situasi sumber daya & kendala
- Definisikan kriteria keberhasilan
- Buat rencana proyek detail

2 Data Understanding

Eksplorasi awal untuk memahami karakteristik, kualitas, dan potensi masalah data yang tersedia.

Aktivitas Utama:

- Kumpulkan data dari semua sumber
- Statistik deskriptif & distribusi
- Identifikasi missing values & outlier
- Dokumentasikan temuan awal

3 Data Preparation

Fase paling time-consuming (60–80% waktu proyek). Transformasi data mentah menjadi dataset siap pakai.

Aktivitas Utama:

- Seleksi atribut & record relevan
- Tangani missing values & noise
- Feature engineering & transformasi
- Integrasi & formatting dataset



4 Modeling

Pemilihan dan pelatihan model machine learning berdasarkan tujuan yang ditetapkan di Fase 1.

Aktivitas Utama:

- Pilih teknik pemodelan yang sesuai
- Split data: train/test/validation
- Bangun & latih model awal
- Hyperparameter tuning & optimasi

5 Evaluation

Evaluasi menyeluruh apakah model benar-benar menjawab tujuan bisnis — bukan hanya akurasi teknis.

Aktivitas Utama:

- Evaluasi terhadap tujuan bisnis
- Review proses: adakah yang terlewat?
- Uji dengan data baru (out-of-sample)
- Putuskan: deploy, iterasi, atau stop

6 Deployment

Integrasi model ke lingkungan produksi dan pemantauan jangka panjang agar nilai bisnis terus terjaga.

Aktivitas Utama:

- Rencanakan integrasi ke sistem ada
- Monitoring performa model real-time
- Retraining & pembaruan berkala
- Dokumentasi & knowledge transfer



Ekosistem Tools Data Science

Python · Google Colab · Jupyter Notebook · GitHub



Python

Pemrograman

- Library: Pandas, NumPy, Matplotlib, Seaborn
- Machine Learning: Scikit-learn, XGBoost
- Deep Learning: TensorFlow, PyTorch
- Komunitas terbesar dunia (Stack Overflow 2023)

Ref: McKinney (2022); VanderPlas (2016)



Google Colab

Cloud

- Gratis, tanpa instalasi, dapat dibuka langsung di browser
- Akses GPU & TPU gratis untuk deep learning
- Terintegrasi Google Drive, simpan & share mudah
- Pre-installed semua library Data Science populer

Ref: Google Colaboratory (2024)



Jupyter Notebook

Lokal

- Standar industri & akademik global
- Gabungkan kode, teks, persamaan, visualisasi
- Reproducible research — dipakai di jurnal ilmiah
- Ekspor ke HTML, PDF, slides, dan lainnya

Ref: Project Jupyter (2024)



GitHub

Kolaborasi

- Git-based version control, lacak semua perubahan
- Kolaborasi tim secara online & asinkron
- Portofolio profesional yang dinilai rekruter
- GitHub Pages untuk publikasi hasil analisis

Ref: GitHub Docs (2024)



Aktivitas Hands-on

Membuat Akun · Konfigurasi Environment · Kode Python Pertama · Latihan



1

Buka Google Colab

Colab

Akses colab.research.google.com via browser. Login dengan akun Google.

2

Buat Notebook Baru

Colab

Klik "+ New notebook". Ganti nama: Pertemuan1_[Nama]_[NIM].ipynb

3

Ketik & Jalankan Kode

Python

Ketik contoh kode Python 4 sel pada slide selanjutnya secara bertahap. Jalankan tiap sel: Ctrl+Enter.

4

Daftar GitHub

GitHub

Buka github.com → Sign up. Username profesional, verifikasi email.

5

Buat Repositori

GitHub

Nama: data-science-2024 (Public). Tambahkan README.md.

6

Upload & Submit

Task

Upload .ipynb ke repo. Salin URL repo → submit via forum diskusi di LMS.



Kode Python

Pertemuan1_NamaMahasiswa.ipynb

```
# SEL 1: Output sederhana
print("Hello, Data Science!")

# SEL 2: Variabel & tipe data
nama      = "Mahasiswa Informatika"
angkatan  = 2024
print(f"Halo, {nama} angkatan {angkatan}!")

# SEL 3: List & perulangan
tools = ["Python", "Colab", "Jupyter", "GitHub"]
for i, tool in enumerate(tools, 1):
    print(f" {i}. {tool}")

# SEL 4: Fungsi Python
def perkenalan(nama, prodi, angkatan):
    return f"{nama} | {prodi} | {angkatan}"
print(perkenalan("Budi", "Informatika", 2024))
```

Output:

Hello, Data Science!

Halo, Mahasiswa Informatika angkatan 2024!

1. Python
2. Google Colab
3. Jupyter Notebook
4. GitHub

Budi | Informatika | 2024

Konsep Python yang Dipelajari

print()	Menampilkan teks ke layar
Variabel	Menyimpan data (str, int, float)
List []	Kumpulan item berurutan
for loop	Iterasi atas setiap elemen
f-string	Interpolasi variabel dalam teks
def fungsi	Mendefinisikan fungsi reusable



Referensi Utama

Buku Teks

- Provost & Fawcett (2013). Data Science for Business. O'Reilly.
- McKinney (2022). Python for Data Analysis, 3rd ed. O'Reilly.
- VanderPlas (2016). Python Data Science Handbook. O'Reilly. [Gratis Online]
- Géron (2022). Hands-on Machine Learning, 3rd ed. O'Reilly.

Artikel Ilmiah

- Cao (2017). Data Science: A Comprehensive Overview. ACM CSUR, 50(3).
- Davenport & Patil (2012). Data Scientist: Sexiest Job of the 21st Century. HBR.
- Donoho (2017). 50 Years of Data Science. J. Comp. & Graphical Statistics.
- Shearer (2000). The CRISP-DM Model. Journal of Data Warehousing, 5(4).
- Dhar (2013). Data Science and Prediction. CACM, 56(12).

Sumber Daring

- Google Colab FAQ: research.google.com/colaboratory/faq.html
- GitHub Docs: docs.github.com/en/get-started
- Python Tutorial Resmi: docs.python.org/3/tutorial
- WEF Future of Jobs Report 2023: weforum.org



Terima Kasih